Laporan Praktikum 4
Association Rule

Prima Surya Nusantara | NRP 5054251036
Data Mining | Algoritma FP-Growth

1. Tujuan dan dataset

Analisis ini menemukan hubungan kehadiran produk pada invoice Online Retail dengan FP-Growth. Dataset lokal memiliki 541,909 baris dan 8 kolom, 25,900 invoice, serta 38 negara. Periode data: 2010-12-01 08:26:00 sampai 2011-12-09 12:50:00. Seluruh negara dianalisis tanpa sampling.

Kolom dataset adalah InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country. InvoiceNo menjadi unit transaksi dan Description menjadi item. CustomerID tidak digunakan sehingga nilai kosong pada kolom tersebut tetap dapat dianalisis.

2. Eksplorasi dan pembersihan

Kolom dengan nilai kosong	Jumlah
Description	1,454
CustomerID	135,080

Description dipangkas spasi tepinya. Penghapusan dilakukan berurutan: Description kosong, invoice pembatalan berawalan C, lalu Quantity nol atau negatif. Jumlah yang dihapus pada setiap tahap tidak saling tumpang tindih.

Tahap	Baris tersisa	Invoice	Baris dihapus
Data awal	541,909	25,900	0
Description kosong	540,455	24,446	1,454
Invoice pembatalan C	531,167	20,610	9,288
Quantity <= 0	530,693	20,136	474

Sebanyak 11,216 baris dikeluarkan. Data bersih memuat 530,693 baris. Harga nol dan CustomerID kosong tetap dipertahankan sesuai ketentuan. Kehadiran produk berulang pada invoice yang sama dihitung satu kali.

3. Persiapan dan metode

Data dikelompokkan per InvoiceNo menjadi daftar Description unik, kemudian dikodekan sebagai one-hot boolean sparse berukuran 20,136 invoice x 4,065 produk. FP-Growth dijalankan tanpa batas panjang itemset, dengan minimum support 0,01 dan minimum confidence 0,5. Ambang awal dipertahankan karena menghasilkan 841 aturan, cukup untuk mengevaluasi tiga aturan terbaik.

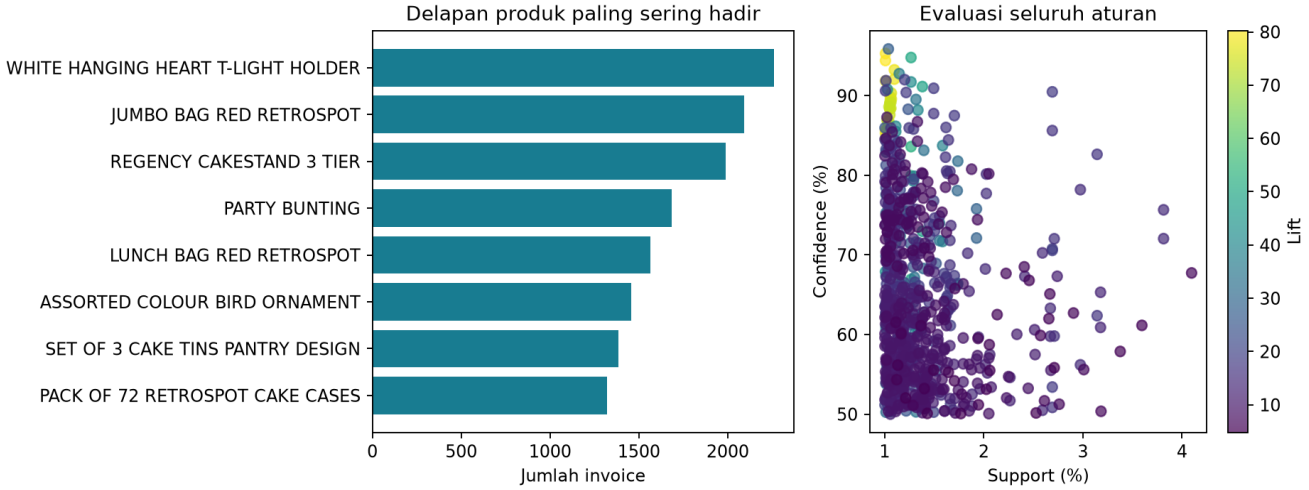
Support(A -> B) = n(A dan B) / N. Confidence(A -> B) = support(A dan B) / support(A). Lift(A -> B) = confidence(A -> B) / support(B). N adalah jumlah invoice bersih. Lift di atas satu menunjukkan asosiasi positif.

4. Hasil dan evaluasi

Diperoleh 1,853 frequent itemset dan 841 aturan. Aturan diurutkan menurut lift menurun, diikuti confidence, support, dan label. Daftar seluruh aturan beserta ketiga metrik ditampilkan dalam notebook dan disimpan di aturan_asosiasi.csv. Berikut tiga peringkat teratas.

#	Antecedent (A)	Consequent (B)	Support	Confidence	Lift
1	HERB MARKER PARSLEY + HERB MARKER ROSEMARY	HERB MARKER THYME	1.01%	94.42%	80.22
2	HERB MARKER THYME	HERB MARKER PARSLEY + HERB MARKER ROSEMARY	1.01%	85.65%	80.22
3	HERB MARKER ROSEMARY	HERB MARKER PARSLEY + HERB MARKER THYME	1.01%	84.58%	79.96

Aturan berarah yang saling berkebalikan tetap dipertahankan apabila masuk tiga peringkat teratas. Lift bersifat simetris, tetapi confidence bergantung pada arah aturan. Pasangan tersebut tidak dianggap sebagai bukti pola bisnis yang independen.



Gambar 1. Frekuensi kehadiran produk dan sebaran support-confidence seluruh aturan. Warna menunjukkan lift. Frekuensi dihitung berdasarkan invoice, bukan jumlah unit.

5. Interpretasi tiga aturan terbaik

Aturan 1: HERB MARKER PARSLEY + HERB MARKER ROSEMARY -> HERB MARKER THYME. Keduanya muncul pada 203 invoice (1.01% dari seluruh invoice). Di antara invoice yang memuat antecedent, 94.42% juga memuat consequent. Frekuensi consequent pada kelompok tersebut 80.22 kali frekuensinya pada seluruh invoice (baseline 1.18%). Kombinasi ini dapat diuji untuk rekomendasi produk pendamping atau penempatan produk berdekatan.

Aturan 2: HERB MARKER THYME -> HERB MARKER PARSLEY + HERB MARKER ROSEMARY. Keduanya muncul pada 203 invoice (1.01% dari seluruh invoice). Di antara invoice yang memuat antecedent, 85.65% juga memuat consequent. Frekuensi consequent pada kelompok tersebut 80.22 kali frekuensinya pada seluruh invoice (baseline 1.07%). Kombinasi ini dapat diuji untuk rekomendasi produk pendamping atau penempatan produk berdekatan.

Aturan 3: HERB MARKER ROSEMARY -> HERB MARKER PARSLEY + HERB MARKER THYME. Keduanya muncul pada 203 invoice (1.01% dari seluruh invoice). Di antara invoice yang memuat antecedent, 84.58% juga memuat consequent. Frekuensi consequent pada kelompok tersebut 79.96 kali frekuensinya pada seluruh invoice (baseline 1.06%). Kombinasi ini dapat diuji untuk rekomendasi produk pendamping atau penempatan produk berdekatan.

6. Kesimpulan

Produk dalam aturan dengan lift tertinggi muncul bersama lebih sering dibandingkan frekuensi dasar consequent. Pola tersebut mendukung pengujian rekomendasi produk pendamping, bundling, dan penataan produk. Pemilihan promosi sebaiknya mempertimbangkan support agar jangkauan memadai, serta margin dan stok yang tidak dianalisis pada praktikum ini.

Hasil merupakan asosiasi, bukan bukti sebab-akibat atau jaminan kenaikan penjualan. Periode 2010-2011, campuran negara, musim, dan pesanan besar membatasi generalisasi. Description dapat memiliki variasi penamaan; entri administratif tidak disaring tambahan. Analisis lanjutan dapat memakai StockCode, segmentasi waktu/negara, dan uji promosi. Metrik tiga aturan teratas telah diverifikasi ulang langsung dari himpunan transaksi.

Referensi dan reproduksi

Instruksi: Tugas Praktikum 4 Association Rule.pdf (berkas lokal). Data: Online Retail.xlsx (berkas lokal yang disediakan), UCI Machine Learning Repository, https://archive.ics.uci.edu/dataset/352/online+retail. Implementasi dan seluruh hasil eksekusi tersedia pada notebook pendamping. Dependensi: pandas, openpyxl, mlxtend, scipy, dan matplotlib.