Deteksi Fraud Kartu Kredit dengan Random Forest

Laporan Tugas Praktikum 3 Ensemble Method dan Class Imbalance

Nama: Prima Surya Nusantara NRP: 5054251036

1. Tujuan dan ringkasan eksperimen

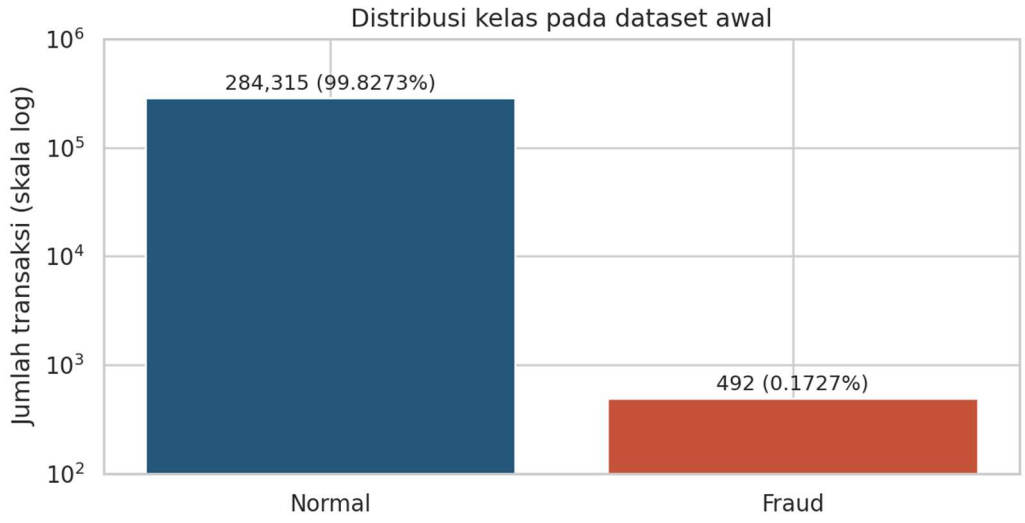
Praktikum ini menguji kemampuan Random Forest untuk mengidentifikasi transaksi penipuan pada data yang sangat tidak seimbang. Model tanpa resampling dibandingkan dengan random undersampling (RUS) pada dua rasio fraud terhadap normal, yaitu 1:10 dan 1:1. Seluruh model dievaluasi pada data uji yang sama tanpa resampling, menggunakan fraud sebagai kelas positif.

Hasil utama menunjukkan trade-off antara fraud yang berhasil ditemukan dan transaksi normal yang salah ditandai. Baseline memperoleh F1 0,8313 dengan 26 fraud terlewat. RUS 1:10 memperoleh F1 0,6098 dengan 20 fraud terlewat; konsekuensinya, false positive berubah dari 2 menjadi 76 transaksi.

2. Dataset dan distribusi kelas awal

Dataset adalah file creditcard.csv yang disertakan bersama tugas, berisi 284.807 baris dan 31 kolom. Target Class bernilai 0 untuk transaksi normal dan 1 untuk fraud. Tiga puluh prediktor numerik terdiri atas Time, V1 sampai V28, dan Amount. Makna bisnis fitur anonim V1 sampai V28 tidak ditafsirkan dari namanya.

Kelas	Jumlah transaksi	Persentase
Normal 0	284.315	99,8273%
Fraud 1	492	0,1727%
Total	284.807	100%



3. Praproses dan rancangan eksperimen

Pemeriksaan menemukan 0 nilai kosong dan 1.081 baris duplikat persis. Duplikat dihapus dengan asumsi merupakan pengulangan rekaman, menghasilkan 283.726 baris, terdiri atas 283.253 normal dan 473 fraud. Penghapusan dilakukan sebelum split untuk mengurangi risiko rekaman identik berada di data latih dan uji. Karena tidak tersedia ID transaksi, asumsi bahwa seluruh duplikat adalah pengulangan belum dapat dipastikan.

Tidak dilakukan imputasi karena tidak ada nilai kosong. Semua prediktor numerik sehingga tidak perlu encoding. Standardisasi tidak diwajibkan untuk Random Forest yang membelah fitur berdasarkan nilai. Outlier dipertahankan karena transaksi ekstrem dapat menjadi pola fraud. Seluruh 30 prediktor digunakan.

Data bersih dibagi dengan train_test_split, test_size=0.2, stratify=y, dan random_state=42. Proporsi kelas dipertahankan sedekat mungkin dengan pembulatan jumlah kasus. Data uji tidak pernah digunakan untuk resampling, pelatihan, atau pemilihan threshold.

Bagian	Normal	Fraud	Total	Fraud persen
Latih	226.602	378	226.980	0,1665%
Uji	56.651	95	56.746	0,1674%

Penanganan class imbalance

RUS mengambil sebagian kelas normal secara acak tanpa pengembalian, sementara seluruh fraud latih tetap dipakai. Rasio 1:10 berarti satu fraud untuk sepuluh normal. Rasio 1:10 ditetapkan sebagai skenario utama dan 1:1 sebagai pembanding yang lebih agresif, sebelum evaluasi. Keduanya mengurangi ketimpangan, tetapi dapat membuang variasi penting kelas normal.

Data latih	Normal	Fraud	Total
Tanpa resampling	226.602	378	226.980
RUS 1:10	3.780	378	4.158
RUS 1:1	378	378	756

Model ensemble dan kontrol perbandingan

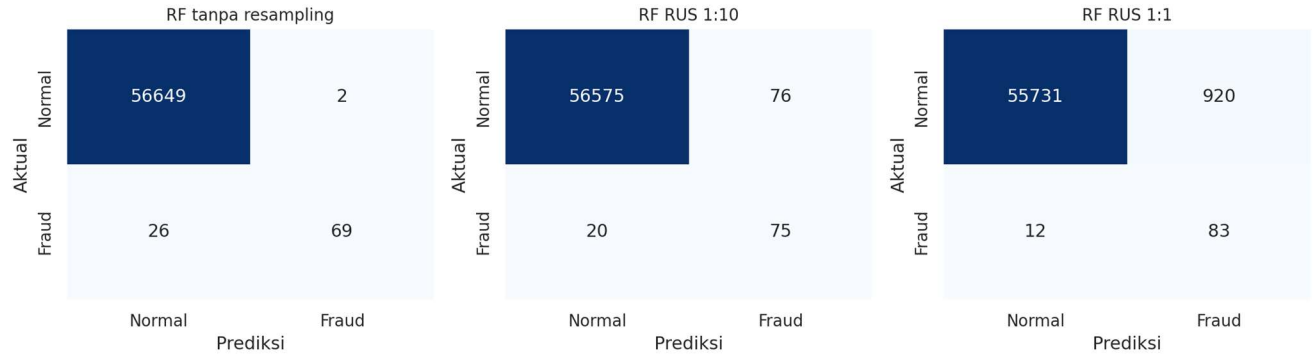
Random Forest membangun banyak pohon dengan sampel bootstrap dan pemilihan subset fitur acak. Prediksi probabilitas kelas dirata-ratakan dari pohon. Ketiga model menggunakan 100 pohon, criterion gini, max_features sqrt, max_depth None, min_samples_leaf 1, class_weight None, bootstrap True, random_state 42, dan n_jobs 4. Hanya data latih yang berbeda. Probabilitas fraud minimal 0,5 diberi label fraud; threshold ini tidak dituning pada data uji.

4. Hasil evaluasi pada kelas fraud

Data uji berisi 56.746 transaksi dengan 95 fraud. Precision mengukur ketepatan alarm fraud, recall mengukur fraud yang tertangkap, dan F1 merangkum keduanya. ROC-AUC menggunakan skor probabilitas. Average precision (AP) ditambahkan untuk merangkum precision-recall; nilainya bukan area trapezoidal kurva PR.

Model	Precision	Recall	F1	ROC AUC	AP
Baseline	0,9718	0,7263	0,8313	0,9239	0,7876
RUS 1:10	0,4967	0,7895	0,6098	0,9698	0,6941
RUS 1:1	0,0828	0,8737	0,1512	0,9733	0,7153

Model	TN	FP	FN	TP	Accuracy
Baseline	56.649	2	26	69	99,95%
RUS 1:10	56.575	76	20	75	99,83%
RUS 1:1	55.731	920	12	83	98,36%

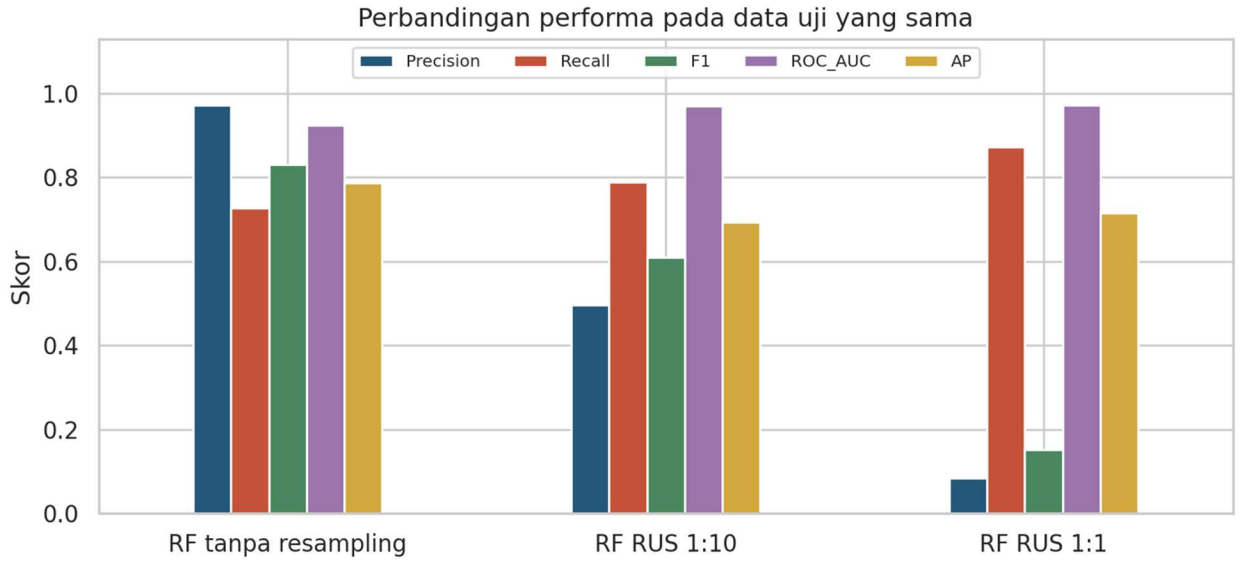


Baseline mendeteksi 69 dari 95 fraud, melewatkan 26, dan menghasilkan 2 alarm keliru. RUS 1:10 mendeteksi 75 fraud dengan 76 alarm keliru. RUS 1:1 mendeteksi 83 fraud dengan 920 alarm keliru. Penambahan alarm normal perlu dihitung sebagai beban pemeriksaan, bukan dianggap otomatis sebagai keberhasilan.

Mengapa accuracy saja tidak cukup

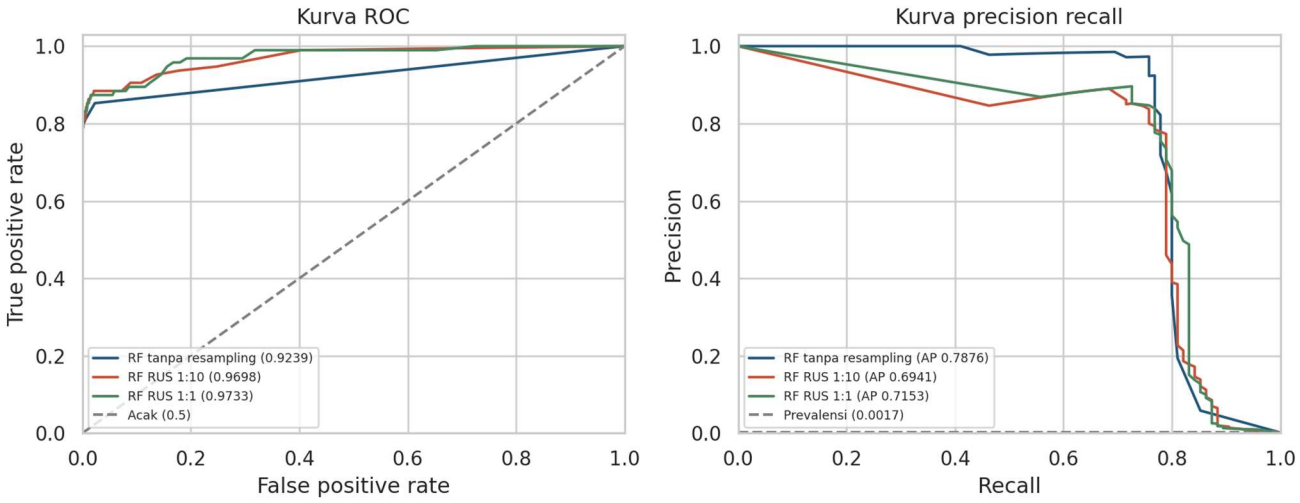
Pembanding yang selalu memprediksi normal menghasilkan accuracy 99,83%, tetapi precision, recall, dan F1 fraud sama dengan nol; seluruh 95 fraud terlewat. ROC-AUC-nya 0,5 dan AP sama dengan prevalensi fraud uji, yaitu 0,0017. Karena transaksi normal mendominasi, accuracy dapat menutupi kegagalan mendeteksi kelas minoritas.

5. Analisis perbandingan model



Dibandingkan baseline, RUS 1:10 mengubah recall sebesar +6.32 poin persentase dan precision sebesar -47.51 poin persentase. Perubahan F1 adalah -0.2216. Fraud terlewat berubah dari 26 menjadi 20; alarm keliru berubah dari 2 menjadi 76. Ini menunjukkan bahwa menambah porsi relatif fraud dalam data latih juga memengaruhi ketepatan alarm.

RUS 1:1 mengubah recall sebesar +14.74 poin persentase dan precision sebesar -88.91 poin persentase terhadap baseline. F1-nya 0,1512. Pengurangan kelas normal yang lebih besar perlu dinilai berdasarkan tambahan fraud tertangkap dan lonjakan false positive, sehingga keseimbangan 50:50 bukan tujuan akhir yang selalu paling baik.



Gambar 4 Kurva ROC dan precision recall dari probabilitas fraud. Garis putus-putus menunjukkan referensi acak pada ROC serta prevalensi fraud pada PR.

ROC-AUC mengukur kualitas pengurutan skor lintas threshold, sedangkan precision dan recall pada tabel menggambarkan satu threshold 0,5. Pada data yang sangat timpang, false positive rate kecil masih dapat menghasilkan banyak alarm normal. AP dan kurva PR melengkapi ROC-AUC dengan memperlihatkan ketepatan alarm pada berbagai tingkat recall. Probabilitas dari model RUS belum dikalibrasi ulang terhadap prevalensi alami.

6. Kesimpulan

Dataset asli sangat timpang dengan fraud hanya 0,1727%. Sesudah pembersihan, pembagian 80:20 berstrata menghasilkan 95 fraud pada data uji. Random Forest mampu mempelajari pola fraud; penanganan imbalance melalui RUS mengubah pertukaran antara fraud terlewat dan alarm keliru, sehingga peningkatan tidak dapat disimpulkan dari accuracy saja.

Pada split dan threshold yang digunakan, F1 tertinggi secara deskriptif diperoleh RF tanpa resampling dengan skor 0,8313. Recall tertinggi diperoleh RF RUS 1:1 dengan skor 0,8737. Peringkat ini adalah deskripsi hasil eksperimen, bukan hasil tuning atau jaminan performa pada transaksi masa depan.

Apabila tujuan pemeriksaan menekankan ketepatan alarm, precision dan beban FP menjadi pertimbangan utama. Apabila biaya fraud terlewat lebih besar, recall dan FN menjadi pertimbangan penting. Tanpa informasi biaya tersebut, tidak ada dasar untuk menyatakan satu model paling baik secara operasional.

7. Saran

Eksperimen hanya memakai satu stratified split dan satu seed. Dengan 95 fraud uji, perubahan satu kasus menggeser recall sekitar 1,05 poin persentase. Belum dilakukan estimasi ketidakpastian atau validasi berulang. Penghapusan duplikat bergantung pada asumsi pengulangan rekaman; kesamaan seluruh nilai belum membuktikan bahwa transaksi memiliki identitas yang sama.

Split acak mengikuti instruksi praktikum dan mengasumsikan distribusi latih dan uji relatif sejenis. Model belum diuji secara temporal terhadap perubahan pola fraud. Undersampling juga mengubah proporsi kelas pada pelatihan dan dapat memengaruhi interpretasi probabilitas.

Pengembangan berikutnya sebaiknya menggunakan validasi silang berstrata hanya pada data latih. Resampling harus diulang di dalam setiap fold. Rasio resampling, parameter model, dan threshold dipilih dari validasi latih berdasarkan biaya FP dan FN, lalu diuji sekali pada data uji terpisah. Uji temporal serta kalibrasi probabilitas layak dipertimbangkan sebelum penggunaan operasional.