

Laporan Praproses Data Prediksi Harga Rumah

Laporan ini menjelaskan pembersihan, transformasi, seleksi fitur, dan reduksi dimensi data untuk prediksi SalePrice. Hasil akhir terdiri atas 1.168 observasi latih dan 292 observasi uji, masing-masing dengan 82 komponen PCA tanpa nilai kosong. Komponen tersebut mempertahankan 95,11% varians fitur data latih.

1. Sumber dan kondisi awal dataset

Analisis menggunakan file train(1).csv dan mengacu pada alur notebook house_sale_prediction.ipynb yang dilampirkan. Hasil dalam laporan dihitung ulang dengan melanjutkan alur tersebut: seluruh outlier dipertahankan, imputasi dilakukan setelah pembagian data, dan PCA menggunakan ambang varians 95%. Dengan demikian, angka di bawah merupakan hasil eksekusi alur lengkap, bukan keluaran PCA yang telah tersimpan dalam notebook awal.

Karakteristik	Hasil pemeriksaan
Observasi dan kolom awal	1.460 baris × 81 kolom
Identitas dan target	Id dan SalePrice
Fitur setelah Id dan target dipisahkan	79 fitur: 35 numerik dan 44 kategoris
Duplikat setelah Id dihapus	0 baris
Nilai kosong saat CSV dibaca	7.829 sel pada 19 kolom
Rentang SalePrice	34.900–755.000; median 163.000


2. Pembersihan identitas dan pemeriksaan duplikat

Kolom Id dihapus karena berfungsi sebagai pengenal observasi dan tidak digunakan sebagai karakteristik rumah. Jumlah kolom berkurang menjadi 80, termasuk target. Pemeriksaan duplikat dilakukan setelah penghapusan Id agar perbedaan nomor identitas tidak menyamarkan baris yang sama. Tidak ditemukan duplikat, sehingga jumlah observasi tetap 1.460.

SalePrice dipisahkan sebagai target regresi dan tidak dimasukkan ke dalam standardisasi, one-hot encoding, maupun PCA. MSSubClass diperlakukan sebagai kategori walaupun disimpan dalam bentuk angka, sebab nilainya menyatakan kelas bangunan. Fitur numerik lainnya mengikuti pembagian pada notebook, termasuk atribut tahun dan penilaian ordinal.

3. Penanganan nilai kosong dan pembagian data

Data dibagi menjadi 80% data latih dan 20% data uji dengan `random_state=42`, menghasilkan 1.168 dan 292 observasi. Sebelum imputasi, fitur data latih mengandung 6.227 nilai kosong dan fitur data uji mengandung 1.602 nilai kosong. Parameter imputasi dipelajari hanya dari data latih, kemudian digunakan pada data uji untuk mencegah kebocoran informasi.



PoolQC, MiscFeature, Alley, dan Fence memiliki banyak nilai kosong. Nilai kosong tidak langsung dijadikan alasan untuk menghapus baris atau atribut. Pada fitur kategoris, nilai tersebut diisi dengan label `Tidak_tercatat`. Label ini mempertahankan informasi bahwa kategori tidak tercatat, tanpa menganggap semua kekosongan sebagai kesalahan atau ketiadaan fasilitas. Pada fitur numerik digunakan median data latih. Median LotFrontage adalah 70, MasVnrArea adalah 0, dan GarageYrBlt adalah 1980. Setelah imputasi, seluruh fitur train dan test tidak lagi mengandung nilai kosong. Pengisian LotFrontage pada seluruh data di notebook awal diganti dengan imputasi setelah split, sehingga median tidak memanfaatkan informasi data uji.


4. Standardisasi dan one hot encoding

Sebanyak 35 fitur numerik distandardisasi menggunakan `StandardScaler` dengan rumus $z = (x - \text{rata-rata train}) / \text{standar deviasi train}$. Hasil pemeriksaan menunjukkan rata-rata setiap fitur train mendekati 0, dengan simpangan numerik maksimum sekitar $6,59 \times 10^{-14}$, dan standar deviasi populasi mendekati 1. Parameter yang sama diterapkan pada data test, rata-rata, dan standar deviasi test tidak harus sama dengan train.

Sebanyak 44 fitur kategoris diproses menggunakan `OneHotEncoder`, menghasilkan 280 kolom indikator. Digabungkan dengan 35 fitur numerik, diperoleh 315 fitur. Encoder tidak menghapus kategori acuan. Opsi `handle_unknown="ignore"` membuat kategori baru pada test direpresentasikan sebagai nol pada seluruh indikator atribut tersebut. Bentuk akhir tahap ini adalah 1.168×315 untuk train dan 292×315 untuk test.

5. Pemeriksaan dan keputusan terhadap outlier

Boxplot pada notebook digunakan untuk menandai nilai ekstrem atribut numerik. Nilai ekstrem tidak otomatis merupakan kesalahan. Pada atribut fasilitas yang sering bernilai nol, sejumlah kecil rumah dengan fasilitas tersebut dapat terdeteksi sebagai outlier walaupun nilainya masuk akal. Karena itu, laporan utama mempertahankan semua observasi.



Aturan $\text{GrLivArea} > 4.000$ dan $\text{SalePrice} < 300.000$ menemukan dua kandidat rumah dengan luas besar tetapi harga relatif rendah. Notebook menyediakan dataset alternatif tanpa kedua kandidat, berisi 1.458 baris. Namun, dataset alternatif tersebut tidak digunakan dalam hasil standardisasi, korelasi, dan PCA pada laporan ini. Dampak penghapusannya baru dapat dinilai melalui perbandingan model yang terpisah.

6. Seleksi fitur berdasarkan korelasi


Korelasi Pearson dihitung pada 35 fitur numerik hasil standardisasi di data latih. Ambang penghapusan adalah nilai absolut korelasi lebih dari 0,90. Pemeriksaan tidak mencakup kolom one-hot, sehingga hasil ini hanya menyatakan kondisi hubungan linear antarfitur numerik asli.

Atribut pertama	Atribut kedua	Korelasi absolut
GarageCars	GarageArea	0,8825
TotalBsmtSF	1stFlrSF	0,8274
GrLivArea	TotRmsAbvGrd	0,8207
YearBuilt	GarageYrBltn	0,7697

Pasangan dengan korelasi paling tinggi adalah GarageCars dan GarageArea sebesar 0,8825. Tidak ada pasangan yang melampaui ambang 0,90; karena itu tidak ada fitur yang dihapus dan jumlah fitur tetap 315. Aturan memilih fitur dengan korelasi target lebih tinggi tidak perlu diterapkan karena tidak ada pasangan yang memenuhi syarat penghapusan. Hasil ini tidak berarti semua fitur bebas dari redundansi atau hubungan nonlinier.

7. Reduksi dimensi menggunakan PCA

PCA diterapkan pada 315 fitur hasil seleksi dengan `n_components=0.95` dan `svd_solver="full"`. Input PCA memadukan fitur numerik terstandarisasi dan indikator one-hot 0/1, indikator tersebut tidak distandarisasi ulang. Dengan demikian, hasil varians PCA bergantung pada representasi dan skala yang dipilih.



PCA menghasilkan 82 komponen, sehingga dimensi berkurang sebanyak 233 fitur atau 73,97% dibandingkan hasil encoding. Varians yang dipertahankan adalah 95,11%, sementara sekitar 4,89% tidak dipertahankan.

8. Ringkasan dataset akhir

Tahap	Data latih	Data uji
Fitur asli setelah pemisahan target	1.168×79	292×79
Imputasi standardisasi dan encoding	1.168×315	292×315
Seleksi korelasi	1.168×315	292×315
PCA	1.168×82	292×82
Target terpisah	y_train: 1.168 nilai	y_test: 292 nilai
Nilai kosong pada hasil PCA	0	0

Dataset akhir siap digunakan untuk pemodelan regresi melalui `X_train_pca`, `X_test_pca`, `y_train`, dan `y_test`. Jumlah observasi tidak berubah; Id dikeluarkan, nilai kosong ditangani, dan semua fitur model telah berupa angka. Versi 315 fitur tetap dapat digunakan sebagai pembanding tanpa PCA. Evaluasi prediksi, misalnya dengan MAE dan RMSE, masih diperlukan untuk menentukan apakah reduksi dimensi memperbaiki performa. Jika dilakukan cross-validation, preprocessing dan PCA perlu dipelajari ulang di dalam setiap fold menggunakan pipeline.